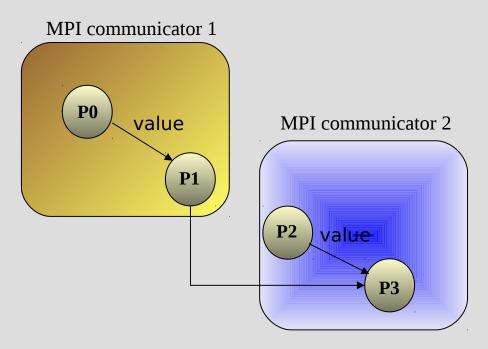
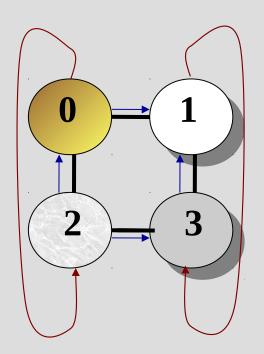
Introducción a la Interfaz de paso de mensajes (MPI)





José Miguel Mantas Ruiz

Depto. de Lenguajes y Sistemas Informáticos Universidad de Granada



Contenido

- 1. Message Passing Interface (MPI)
- 2. Funciones MPI básicas
- 3. Envío y recepción simultánea
- 4. Operaciones de comunicación colectiva
- 5. Comunicación No bloqueante
- 6. Comunicadores
- 7. Topologías Cartesianas
- 8. Tipos de datos derivados y Empaquetado
- 9. Referencias útiles

1. Message Passing Interface (MPI)

Funciones para paso de mensajes y operaciones. complementarias (>120 rutinas con numerosos parámetros y variantes).

"Interfaz" estándar para C y Fortran con diversas implementaciones.

Objetivo diseño: paso de mensajes portable y fácil de usar.

Basta con un pequeño subconjunto de MPI.

Modelo de Programación en MPI:

<u>Computación</u> ⇒ Número fijado de procesos se comunican mediante llamadas a funciones de envío y recepción de mensajes.

Modelo básico: SPMD

Extensión: cada proceso puede ejecutar diferentes programas → MPMD

Creación e inicialización de procesos

No definido en el estándar: depende implementación.

En mpich: mpirun prog1 -machinefile maquinas -np 4

Comienza 4 copias del ejecutable "prog1".

La asignación de procesos a máquinas se define en el archivo "maquinas".

1. Message Passing Interface (MPI)

1.1. Asuntos de implementación

```
#include "mpi.h"
```

Define ctes, tipos de datos y los prototipos de las funciones MPI

Funciones devuelven código de error

MPI_SUCCESS ⇒ Ejecución correcta

MPI_Status: estructura con 2 campos:

status.MPI_SOURCE: proceso fuente status.MPI_TAG: etiqueta del mensaje.

Tipos de datos MPI

MPI_CHAR, MPI_INT, MPI_LONG, MPI_UNSIGNED_CHAR, MPI_UNSIGNED, MPI_UNSIGNED_LONG, MPI_FLOAT, MPI_DOUBLE, MPI_LONG_DOUBLE, etc.

Comunicador = Grupos de procesos + contexto

MPI_INIT: Inicializa entorno de ejecución MPI.

MPI_FINALIZE: Finaliza entorno de ejecución MPI.

MPI_COMM_SIZE: Determina nº procesos del comunicador.

MPI_COMM_RANK: Determina id. proceso en el comunicador.

MPI_SEND: Envío básico mensaje.

MPI_RECV: Recepción básica mensaje.

2.1. Iniciando y finalizando MPI

int MPI_Init (int *argc, char ***argv)

Llamado antes de cualquier otra función MPI

Llamar más de una vez durante ejecución ⇒ Error

Argumentos argc, argv: Argumentos de la línea de orden del progr.

int MPI_Finalize ()

Llamado al fin de la computación: Tareas de limpieza para finalizar entorno de ejecución

2.2. Introducción a los Comunicadores

Comunicador = variable de tipo MPI_Comm = Grupo_procs + Contexto

Grupo de procesos: Subconjunto de procesos

Contexto de comunicación: Ámbito de paso de mensajes en el que se comunican dichos procesos. Un mensaje enviado en un contexto sólo se conoce en ese contexto ⇒ elemento del "sobre" del mensaje.

Argumento en funciones de transferencia.

MPI_COMM_WORLD: Comunicador MPI por defecto Incluye todos los procesos en ejecución

MPI_COMM_WORLD

P0 P1 P2 P3 P4 P5

P6 P7 P8 P9 P10 P11

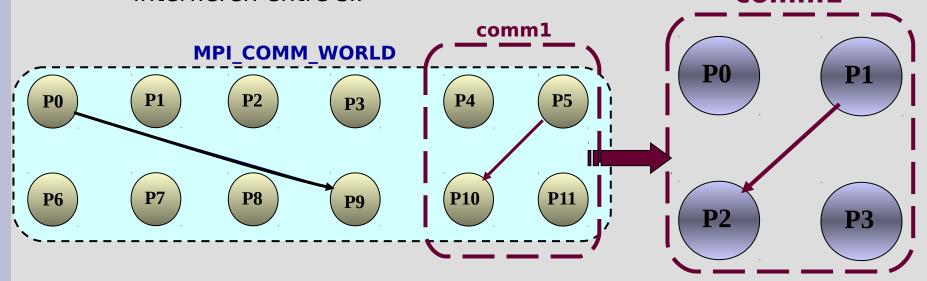
2.2. Introducción a los Comunicadores (cont.)

Identificación unívoca de procesos participantes en comunicador

Un proceso puede pertenecer a diferentes comunicadores

Cada proceso tiene un identificador: desde 0 a size_comm-1

Mensajes destinados a diferentes contextos de comunicación no interfieren entre sí.



2.3. Obteniendo Información

MPI_Finalize(); return 0;}

```
int MPI_Comm_size ( MPI_Comm comm, int *size ) 
 size= n^{o} de procs que pertenecen al comunicador comm. 
 Ej.: MPI_Comm_size ( MPI_COMM_WORLD, &size) \Rightarrow size = n^{o} total de procs. 
 int MPI_Comm_rank ( MPI_Comm comm, int *rank ) 
 rank= Identificador del proceso llamador en comm.
```

```
#include <stdio.h>
#include "mpi.h"
int main(int argc, char **argv) {
int rank, size;
MPI_Init( &argc, &argv);
MPI_Comm_size( MPI_COMM_WORLD, &size );
MPI_Comm_rank( MPI_COMM_WORLD, &rank );
printf( "Hello world from process %d of %d\n", rank, size );
```

2.4. Envío y recepción de mensajes

int MPI_Send (void *buf, int count, MPI_Datatype datatype, int dest, int tag, MPI_Comm comm)

Envía datos almacenados en buffer (count elem. de tipo datatype) apuntado por buf al proc. dest con la etiqueta tag (entero >0) dentro del comunicador comm.

Existen implementaciones bloqueantes y <u>no bloqueantes</u>

int MPI_Recv (void *buf, int count, MPI_Datatype datatype, int source, int tag, MPI_Comm comm, MPI_Status *status)

Recibe mensaje de proceso source dentro del comunicador comm. Semántica bloqueante

Sólo se recibe un mensaje enviado desde source con etiqueta tag pero existen argumentos comodín: MPI_ANY_SOURCE, MPI_ANY_TAG.

Mensaje es almacenado en posiciones continuas desde buf.



2.4. Envío y recepción de mensajes (cont.)

```
Argumentos count y datatype: especifican la longitud del buffer.

Objeto status → Estructura con campos MPI_SOURCE y MPI_TAG.

Permite obtener información sobre el mensaje recibido

Obtener tamaño del mensaje recibido: Función MPI_Get_count

int MPI_Get_count( MPI_Status *status, MPI_Datatype dtype, int *count )
```

Ejemplo: Programa para dos procesos

2.4. Envío y recepción de mensajes. Ejemplo

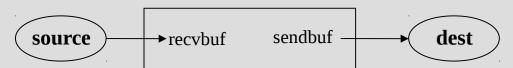
```
#include <stdio.h>
#include "mpi.h"
                                                    value
int main(int argc, char **argv); {
int rank, value, size; MPI_Status status;
                                                             value
MPI_Init( & argc, & argv );
                                                                   P2
                                                                       value
MPI_Comm_rank( MPI_COMM_WORLD, &rank );
MPI_Comm_size( MPI_COMM_WORLD, &size );
do {
if (rank == 0) { scanf( "%d", &value );
      MPI_Send( &value, 1, MPI_INT, rank + 1, 0, MPI_COMM_WORLD ); }
else { MPI_Recv( &value, 1, MPI_INT, rank - 1, 0, MPI_COMM_WORLD, &status );
     if (rank < size - 1) MPI_Send( &value, 1, MPI_INT, rank + 1, 0, MPI_COMM_WORLD )}
printf( "Process %d got %d\n", rank, value ); }
while (value >= 0); MPI_Finalize(); return 0; }
```

3. Envío y recepción simultánea

int MPI_Sendrecv(void *sendbuf, int sendcount, MPI_Datatype sendtype, int dest, int sendtag, void *recvbuf, int recvcount, MPI_Datatype recvtype, int source, int recvtag, MPI_Comm comm, MPI_Status *status)

Envía un mensaje a dest y simultáneamente los recibe de source Muy útil para patrones de comunicación circulares Combina argumentos de MPI_Send y MPI_Recv.

Los buffers deben ser disjuntos, y se permite que source=dest



int MPI_Sendrecv_replace(void *buf, int count, MPI_Datatype datatype, int dest, int sendtag, int source, int recvtag, MPI_Comm comm, MPI_Status *status)

Igual que MPI_Sendrecv pero con un único buffer.

Los datos recibidos reemplazan a los enviados.

Tanto send como receive tratan con datos del mismo tipo.

Tienen un comunicador como argumento: define el grupo afectado.

Participan todos los procesos del comunicador:

La deben llamar todos con los mismos parámetros.

MPI_Barrier: Sincroniza todos los procesos.

MPI_Broadcast: Envía un dato de un proc. al resto.

MPI_Gather: Recolecta datos de todos los procesos a uno.

MPI_Scatter: Reparte datos de un proceso a todos.

MPI_Reduce: Realiza operaciones simples sobre datos distribuidos.

MPI_Scan: Operación de reducción de prefijo.

4.1. Sincronización de barrera

int MPI_Barrier (MPI_Comm comm)

Bloquea todos los procesos de comm hasta que todos la invoquen.

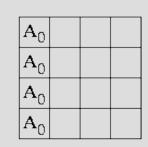
4.2. Movimiento de datos

Todos los procesos interactúan con un proceso distinguido (root) para difundir, recolectar o repartir datos

processes A₀

one-to-all broadcast

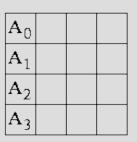
MPI_BCAST

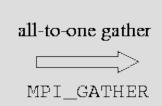


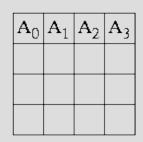
int MPI_Bcast (void* buffer, int count, MPI_Datatype datatype, int root, MPI_Comm comm)

Envía datos almacenados en buffer (count elem. de tipo datatype) en root al resto.

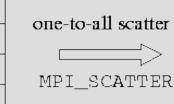
Datos recibidos se almacenan en buffer, count y datatype deben coincidir en todos.







\mathbf{A}_0	\mathbf{A}_1	\mathbf{A}_2	A ₃



\mathbf{A}_0		
\mathbf{A}_1		
A ₂		
$\overline{\mathbf{A}_3}$		

4.2. Movimiento de datos (cont.)

```
int MPI_Gather (void* sendbuf, int sendcount, MPI_Datatype sendtype, void* recvbuf, int recvcount, MPI_Datatype recvtype, int root, MPI_Comm comm )
Cada proceso envía datos almacenados en el array sendbuf a root.
Proc root recibe size(comm) buffers dispuestos consecutivamente en recvbuf.
```

Argumentos sendtype y sencount \rightarrow mismos valores en todos los procs. recvcount= n^{o} items recibidos de cada proc \Rightarrow recvcount=sendcount, si sendtype coincide con recvtype.

Información sobre buffer de recepción sólo tiene sentido en root.

int MPI_Scatter(void* sendbuf, int sendcount, MPI_Datatype sendtype, void* recvbuf, int recvcount, MPI_Datatype recvtype, int root, MPI_Comm comm) source envía una parte diferente de sendbuf al recvbuf de cada proc. Todos con mismos valores de sendcount, sendtype, recvbuf, recvcount, recvtype, root y comm.

sendcount=nº items enviados por cada proc

4.3. Operaciones de Reducción Global

int MPI_Reduce (void* sendbuf, void* recvbuf, int count, MPI_Datatype datatype, MPI_Op op, int root, MPI_Comm comm)

Combina los elementos almacenados en sendbuf de cada proc, usando operación op. Devuelve resultado en recybuf de root.

Args sendbuf y recybuf deben tener count items de tipo datatype.

Todos deben proporcionar array recvbuf

Si $count > 1 \Rightarrow$ la operación se aplica elemento a elemento.

Args count, datatype, op, root, comm deben ser idénticos en todos.

Operaciones predefinidas

MPI_MAX (máximo), MPI_MIN (mínimo), MPI_SUM (suma), MPI_PROD (producto), MPI_LAND (AND lógico), MPI_BAND (AND bit a bit), MPI_LOR (OR lógico), PI_BOR (OR bit a bit), MPI_LXOR (XOR lógico), MPI_BXOR (XOR bit a bit).

Es posible definir otras operaciones: MPI_OP_CREATE .

Initial

Data:

4.3. Operaciones de Reducción Global (cont.)

int MPI_Allreduce(void* sendbuf, void* recvbuf, int count, MPI_Datatype datatype, MPI_Op op, MPI_Comm comm)

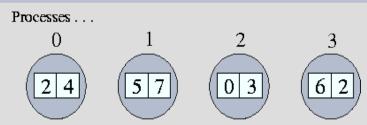
El resultado es replicado ⇒ Argumento root no es necesario

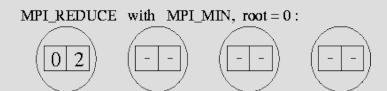
int MPI_Scan (....)

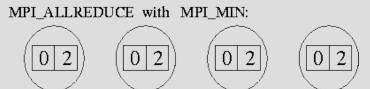
Argumentos de MPI_Allreduce.

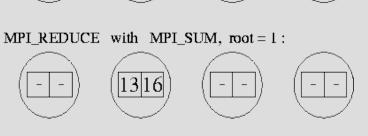
Calcula reducciones parciales en cada proc.

Proc i calcula la reducción aplicada a los procesos 0, ...,i.









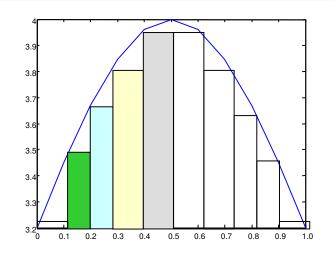
4.4. Ejemplos

```
Difunde 20 reales de proceso 0 al resto en comunicador comm
    double vector[20];
    MPI_Bcast (vector, 20, MPI_DOUBLE, 0, comm);
Recoge 20 reales de cada proceso en el proceso 0
   MPI_Comm comm= MPI_COMM_WORLD;
   int gsize; double invec[20], *outvec;
   MPI_Comm_size( comm, &gsize);
   outvec = (double *)malloc(gsize*20*sizeof(double));
   MPI_Gather (invec, 20, MPI_DOUBLE, outvec, 20, MPI_DOUBLE, 0, comm);
Inversa anterior: Reparte 20 reales desde proc 0
  MPI_Scatter( outvec, 20, MPI_DOUBLE, invec, 20, MPI_DOUBLE, 0, comm);
```

4.4. Ejemplos. Cálculo de π

```
#include "mpi.h"
#include <math.h>
int main(int argc, char **argv) {
int n, myid, numprocs, i; double mypi, pi, h, sum, x;
MPI_Init (&argc,&argv);
MPI_Comm_size (MPI_COMM_WORLD,&numprocs);
MPI_Comm_rank (MPI_COMM_WORLD,&myid);
if (myid == 0) { printf("Number of intervals: "); scanf("%d",&n); }
MPI_Bcast (&n, 1, MPI_INT, 0, MPI_COMM_WORLD);
h = 1.0 / (double) n; sum = 0.0;
for (i = myid + 1; i \le n; i += numprocs)
                { x = h * ((double)i - 0.5); sum += 4.0 / (1.0 + x*x); }
mypi = h * sum;
MPI_Reduce (&mypi, &pi, 1, MPI_DOUBLE, MPI_SUM,
                            0, MPI COMM WORLD);
if (myid == 0) printf("pi is approximately %.16f, \n", pi); MPI_Finalize(); return 0; }
```

$$\pi = \int_{0}^{1} \frac{4}{1 + x^{2}}$$



Las operaciones de comunicación vistas son "bloqueantes" Incluso MPI_Send puede ser bloqueante si la implementación no soporta suficiente buferización.

Se necesitan operaciones de comunicación no bloqueantes Solapar comunicación con computación:

MPI_Isend: Inicia envío pero retorna antes de copiar en buffer.

MPI_Irecv: Inicia recepción pero retorna antes de recibir.

MPI_Test: Chequea si la operación no bloqueante ha finalizado.

MPI_Wait: Bloquea hasta que acabe la operación no bloqueante.

Comunicación Asíncrona, .

MPI_Iprobe: Chequeo no bloqueante para un mensaje.

MPI_Probe: Chequeo bloqueante para un mensaje.

5.1. Solapando Comunicación con Computación

```
int MPI_Isend(void* buf, int count, MPI_Datatype datatype, int dest, int tag, MPI_Comm comm, MPI_Request *request)
```

int MPI_Irecv(void* buf, int count, MPI_Datatype datatype, int source, int tag, MPI_Comm comm, MPI_Request *request)

Argumento request: Identifica operación cuyo estado se pretende consultar o se espera que finalice.

No incluyen argumento status: Se obtiene con otras 2 funciones

```
int MPI_Test(MPI_Request *request, int *flag, MPI_Status *status)
    flag > 0 ⇒ operación identificada ha finalizado, libera request ,
        inicializa status
```

```
Versión para varias count operaciones : int MPI_Testall (int count, MPI_Request *array_of_requests, int *flag, MPI_Status *array_of_statuses)
```

5.1. Solapando Comunicación con Computación (cont.)

```
int MPI_Wait(MPI_Request *request, MPI_Status *status)
    Bloquea hasta que operación finaliza
    Versión para varias count operaciones : int MPI_Waitall( int count, MPI_Request array_of_requests[], MPI_Status array_of_statuses[])
```

Posible conectar operaciones no bloqueantes con contrapartes bloqueantes

```
int MPI_Request_free(MPI_Request *request) ⇒ Liberación explícita request
```

5.2. Comunicación Asíncrona. Sondeo de

Acceso no estructurado a recurso compartido Comprobar existencia de mensajes sin recibirlos

No bloquea si no hay mensajes,. Si hay mensaje, se recibe con MPI_Recv

flag > $0 \Rightarrow \exists$ mensaje pendiente que encaja con (source, tag, comm).

Más información mediante status.

int MPI_Probe(int source, int tag, MPI_Comm comm, MPI_Status *status)

Retorna sólo cuando hay mensaje que encaje con los argumentos.

Esperar la llegada mensaje sin conocer procedencia, etiqueta o tamaño.

5.2. Comunicación Asíncrona. Ejemplo.

Recepción de fuente desconocida

```
int count, *buf, source;
MPI_Probe(MPI_ANY_SOURCE, 0, comm, &status);
MPI_Get_count(status, MPI_INT, &count);
buf=malloc(count*sizeof(int));
source= status.MPI_SOURCE;
MPI_Recv(buf, count, MPI_INT, source, 0, comm, &status);
```

6. Comunicadores

Operación colectiva que divide grupo asociado a comm en subgrupos, cada uno asociado a un comunicador diferente comm_out.

Cada subgrupo contiene los procesos con el mismo valor de color.

color=MPI_UNDEFINED ⇒proceso no pertenece a nuevo grupo

La ordenación en el nuevo grupo se hace en base a key.

int MPI_Comm_free(MPI_Comm *comm)
Libera el comunicador comm

6. Comunicadores

6.1. Ejemplos de creación de comunicadores

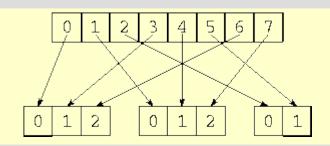
MPI_Comm comm1,comm2,comm3;

int myid, color;

MPI_Comm_rank(comm, &myid);

color = myid%3;

MPI_Comm_split (comm, color, myid, &comm1);



if (myid < 8) color = 1; else color = MPI_UNDEFINED;

MPI_Comm_split (comm, color, myid, &comm2);

comm2= Nuevo Comunicador con 8 primeros procs de comm.

MPI_Comm_split (comm, 0, myid, &comm3);

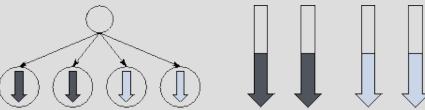
comm3= Nuevo Comunicador con el mismo grupo de procs que comm.

6. Comunicadores

6.2. Objetivos de los Comunicadores. Modularidad

Restringir determinadas operaciones comunicación a ciertos grupos → Implementación modelo MPMD

Programación por grupos



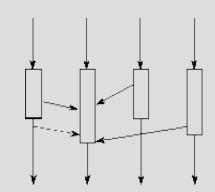
Separar paso de mensajes en grupos de procesos solapados.

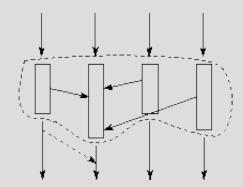
Etiquetas no bastan. Fallan para desarrollo modular.

Aplicación que usa módulo de biblioteca

Asegurar que el módulo usa diferentes etiquetas

Solución: Nuevo comunicador Argumento del módulo Desacopla paso de mensajes





7. Topologías Cartesianas

```
Numeración lineal (0,...,P-1) → No apropiada para algunas aplicaciones.
```

Ejemplo: Algoritmos de multiplicación de matrices → Malla 2D Asignar proceso MPI a un proceso en una topología n-dimensional

7.1. Creación

```
int MPI_Cart_create ( MPI_Comm comm_old, int ndims, int *dims, int
    *periods, int reorder, MPI_Comm *comm_cart )
    Crea comunicador cartesiano comm_cart con ndims dimensiones a
    partir de comm.
    dims[i] = número de procesos en dimensión i-ésima.
```

 $periods[i] > 0 \Rightarrow dimensión i periódica, periods[i]=0 \Rightarrow No periódica reorder=0 \Rightarrow Se sigue la numeración de comm.$

reorder>0 ⇒ Se permite que MPI reordene la numeración según su conveniencia, por ejemplo, para hacer coincidir la topología con la topología física de la red.

7. Topologías Cartesianas

7.2. Identificación de procesos.

```
int MPI_Cart_coords (MPI_Comm comm_cart, int rank, int maxdims, int *coords )
```

Devuelve coordenadas del proceso rank dentro del comunicador cartesiano comm_cart con maxdims dimensiones coords= array, coordenadas del proc. en cada dimensión.

int MPI_Cart_rank (MPI_Comm comm_cart, int *coords, int *rank)

Devuelve el identificador (rank) del proceso que tiene las
coordenadas coords en el comunicador cartesiano comm_cart.

Devuelve el identificador de los procesos fuente y destino (source, dest) para una operación de desplazamiento de displayos (displ $>0 \rightarrow$ arriba, $<0 \rightarrow$ abajo) en la dimensión direction dentro de comm_cart.

7. Topologías Cartesianas

7.3. Ejemplo.

```
MPI_Comm comm_2d;
int myrank, size, P, Q, p, q, reorder; MPI_Status status;
int dims[2], local[2], period[2];
int remain_dims[2],izqda, dcha, abajo, arriba;
double buf;
MPI_Comm_rank (MPI_COMM_WORLD, &myrank);
dims[0] = dims[1] = 2; reorder = 0; period[0] =1; period[1] = 0;
MPI_Cart_create(MPI_COMM_WORLD, 2, dims, period,
                                                          reorder, &comm 2d);
MPI_Cart_coords(comm_2d, myrank, 2, local);
MPI_Cart_shift(comm_2d, 0, 1, &arriba, &abajo);
MPI_Sendrecv_replace( &buf, 1, MPI_DOUBLE, arriba, 0, abajo, 0, comm_2d, &status)
```

```
int MPI_Type_commit ( MPI_Datatype *datatype )

Prepara el nuevo tipo datatype para su uso en una función de comunicación.
```

```
int MPI_Type_free ( MPI_Datatype *datatype )
    Libera el tipo de datos datatype
```

8.1. Ejemplo de Tipos de datos derivados

```
Enviar un bloque 4x4, comenzando por A[0][2] de una matriz
  A de proceso 0 al 1
float A[10][10];
MPI_Datatype bloque;
MPI_Type_vector(4,4,10,MPI_FLOAT,&bloque);
MPI_Type_commit(&bloque);
If (myrank==0)
  MPI\_Send(&(A[0][2]), 1, bloque, 1, 0, MPI\_COMM\_WORLD);
else
  MPI_Recv(&(A[0][2]),1,bloque, 0, 0, MPI_COMM_WORLD,
```

&status);

8.3. Empaquetando datos

```
int MPI_Pack (void *inbuf, int incount, MPI_Datatype datatype, void *outbuf, int outcount, int *position, MPI_Comm comm )
```

Empaqueta mensaje (inbuf, incount, datatype) en <u>área contigua</u> con outcount bytes, desde outbuf.

Entrada position = $1^{\underline{a}}$ posición buffer salida a usar para empaquetar.

position se incrementa en el tamaño del mensaje empaquetado Salida de position = 1^{a} posición en buffer salida después empaquetar.

comm= comunicador para enviar mensaje empaquetado. Mensaje empaquetado se envía como tipo MPI_PACKED

Función de Temporización (para medir tiempos)

double MPI_Wtime() → Tiempo de retardo (en segs.) desde un tiempo arbitrario en el pasado.

8.3.1. Desempaquetando datos

int MPI_Unpack (void *inbuf, int insize, int *position, void *outbuf, int outcount, MPI_Datatype datatype, MPI_Comm comm)

Desempaqueta mensaje en (outbuf, outcount, datatype) desde el área contigua con insize bytes que comienza en inbuf.

Entrada position = 1º posición en buffer de entrada ocupada por el mensaje empaquetado.

position se incrementa en el tamaño del mensaje empaquetado Salida de position= 1º posición en buffer entrada después de empaquetar posiciones ocupadas por el mensaje desempaquetado.

comm=comunicador para recibir mensaje empaquetado

8.3.2. Empaquetando datos. Ejemplo

```
int position, i, j, a[2]; char buff[1000]; MPI_Comm comm= MPI_COMM_WORLD;
MPI_Comm_rank(MPI_COMM_WORLD, &myrank);
if (myrank == 0)
  { position = 0;MPI_Pack(&i, 1, MPI_INT, buff, 1000, &position, comm);
    MPI_Pack(&j, 1, MPI_INT, buff, 1000, &position, comm);
    MPI_Send( buff, position, MPI_PACKED, 1, 0, comm); }
else
   MPI_Recv( a, 2, MPI_INT, 0, 0 , comm);
   /* ALTERNATIVA A LO ANTERIOR */
            { MPI_Recv( buff, 1000, MPI_PACKED, 0, 0, &status);
             position = 0; MPI_Unpack(buff, 1000, &position, &i, 1, MPI_INT, comm);
             MPI_Unpack(buff, 1000, &position, &j, 1, MPI_INT, comm) }
```

9. Referencias útiles

Referencias bibliográficas

Open MPI: Open Source High Performance Computing http://www.open-mpi.org/

MPI Forum

http://www.mpi-forum.org

Parallel Programming with MPI

Peter S. Pacheco, Morgan Kaufman Publishers, Inc

Using MPI: Portable Parallel Programing with Message Passing Interface

William Gropp, E. Lusk and A. Skjellum, MIT Press